

Análisis de Representaciones Latentes bajo Penalización de Neural Collapse

Efectos de la regularización NCC en las propiedades
geométricas del espacio de representación

Análisis original — Repositorio `grokking_flatness`

14 de julio de 2026

Índice general

1. Introducción	2
1.1. ¿Qué es Neural Collapse?	2
1.2. Motivación: ¿Es NC necesario para generalizar?	3
1.3. Estructura del documento	3
2. Cómo Extraer Embeddings	4
2.1. ResNet-18 (experimentos nc_experiments)	4
2.2. ResNet-18 (experimentos rf_resnet18)	5
2.3. Transformer de Grokking (grokking_nc_rf)	5
2.3.1. Resumen comparativo	5
3. La Métrica NCC	7
3.1. Definición formal	7
3.2. Interpretación geométrica	7
3.3. Implementación en el código	8
3.3.1. Detalles técnicos importantes	8
3.4. Relación con otras métricas de colapso	8
4. Efecto de la Penalización NCC sobre las Representaciones	10
4.1. Formulación de la función de pérdida	10
4.2. Análisis del gradiente inducido	10
4.2.1. Interpretación de las componentes del gradiente	11
4.3. Consecuencias observables	11
4.4. Ejemplo sintético	12
5. Hipótesis: Colapso Alternativo	13
5.1. Marco conceptual	13
5.2. Hipótesis de Colapso por Subespacios (Subspace Collapse)	14
5.2.1. Justificación	14
5.2.2. Consecuencias	14
5.3. Hipótesis de Colapso Suave (Soft Collapse)	14
5.3.1. Formalización	15
5.4. Hipótesis de Colapso Inducido por Kernel (Kernel-Induced Collapse)	15
5.4.1. Desarrollo	15
5.5. Hipótesis de Colapso con Rango Constreñido (Rank-Constrained Collapse)	16
5.5.1. Análisis	16
5.6. Unificación: La pérdida como un tradeoff geométrico	16
5.7. Evidencia empírica preliminar	17

6. Propuestas de Análisis	18
6.1. Análisis de NCC por capas	18
6.2. Análisis de Componentes Principales (PCA) de las medias de clase	18
6.3. Información Mutua entre Representación y Etiqueta	19
6.4. Distancias geodésicas en el manifold de representaciones	19
6.5. Análisis de la matriz Gram de medias	20
6.6. NCC local vs. global	20
6.7. Análisis de la topología del espacio de representación	20
6.8. Visualización mediante UMAP / t-SNE	21
7. Conclusiones	22
7.1. Síntesis de los hallazgos	22
7.2. Hacia una teoría unificada	23
7.2.1. Trabajo futuro	23
7.3. Reflexión final	23
A. Detalles de Implementación en el Código	24
A.1. Cálculo de Sharpness	24
A.2. Variantes de regularización en rf_resnet18	24
A.3. Extracción de representaciones en ViT y BERT	25

Capítulo 1

Introducción

1.1. ¿Qué es Neural Collapse?

El fenómeno de *Neural Collapse* (NC) fue formalizado por Papayan et al. [1] en el contexto de clasificación supervisada con redes neuronales profundas entrenadas más allá del punto de sobreajuste (i.e., cuando el error de entrenamiento es cero). En esta condición, las representaciones de la última capa oculta y los pesos del clasificador exhiben cuatro propiedades geométricas notables:

NC1: **Varianza intra-clase colapsa a cero** (NC1). Para cada clase c , la varianza de sus representaciones $h_i^{(c)} \in \mathbb{R}^p$ tiende a cero:

$$\Sigma_W^{(c)} = \frac{1}{n_c} \sum_{i=1}^{n_c} (h_i^{(c)} - \mu_c)(h_i^{(c)} - \mu_c)^\top \longrightarrow 0, \quad (1.1)$$

donde μ_c es el vector media de la clase c y n_c el número de ejemplos de esa clase.

NC2: **Convergencia de medias a un ETF** (NC2). Las medias de clase μ_c , centradas respecto a la media global μ_G , convergen a un marco tensorial equiangular (*Equiangular Tight Frame*, ETF):

$$\frac{\tilde{\mu}_c}{\|\tilde{\mu}_c\|} \quad \text{donde} \quad \tilde{\mu}_c = \mu_c - \mu_G, \quad (1.2)$$

y para todo par (c_1, c_2) con $c_1 \neq c_2$:

$$\langle \tilde{\mu}_{c_1}, \tilde{\mu}_{c_2} \rangle = -\frac{1}{K-1}, \quad (1.3)$$

con K el número de clases. En otras palabras, las medias de clase forman un simplex regular en el espacio de representación.

NC3: **Convergencia a autodualidad** (NC3). Los pesos del clasificador lineal $W \in \mathbb{R}^{K \times p}$ se alinean con las medias de clase:

$$\frac{W_c}{\|W_c\|} \longrightarrow \frac{\tilde{\mu}_c}{\|\tilde{\mu}_c\|}. \quad (1.4)$$

NC4: **Comportamiento del clasificador residual** (NC4). El clasificador por vecino más cercano a las medias (NMC) produce la misma decisión que el clasificador lineal:

$$\arg \max_c \langle W_c, h \rangle + b_c \longleftrightarrow \arg \min_c \|h - \mu_c\|. \quad (1.5)$$

Estas propiedades emergen de manera consistente en una amplia variedad de arquitecturas (ResNet, Transformers, etc.) y conjuntos de datos (CIFAR-10/100, ImageNet, etc.) cuando el modelo ha alcanzado el sobreajuste completo.

1.2. Motivación: ¿Es NC necesario para generalizar?

El trabajo de Han et al. [2] plantea una pregunta fundamental: ¿es *necesario* Neural Collapse para la generalización? Sus experimentos demuestran que, al penalizar explícitamente la métrica NCC (Neural Collapse Clustering) durante el entrenamiento, el modelo puede alcanzar alta precisión en test incluso mientras las representaciones NO exhiben colapso neural en el sentido clásico. Este hallazgo cuestiona la narrativa predominante de que NC es un prerequisite para la generalización [1, 3].

En este documento analizamos en profundidad el efecto de la penalización NCC sobre la geometría del espacio de representaciones y proponemos formas alternativas de «colapso» que podrían estar ocurriendo bajo estas condiciones de entrenamiento.

1.3. Estructura del documento

En el Capítulo 2 describimos cómo se extraen las representaciones latentes en los distintos experimentos del repositorio. En el Capítulo 3 definimos formalmente la métrica NCC y su implementación. En el Capítulo 4 analizamos el efecto de la penalización sobre las representaciones. En el Capítulo 5 presentamos nuestra contribución principal: la hipótesis de formas alternativas de colapso. En el Capítulo 6 proponemos análisis concretos para validar estas hipótesis. Finalmente, en el Capítulo 7 sintetizamos las conclusiones.

Capítulo 2

Cómo Extraer Embeddings

2.1. ResNet-18 (experimentos nc_experiments)

En los experimentos de colapso neural con ResNet-18, la extracción de la representación latente se realiza en el método `forward()` de la clase `ResNet` (archivo `nc_experiments/resnet18.py`).

```
1 def forward(self, x: Tensor) -> Tensor:
2     x = self.conv1(x)          # Primera convolucion
3     x = self.bn1(x)
4     x = self.relu(x)
5     x = self.maxpool(x)
6     x = self.layer1(x)
7     x = self.layer2(x)
8     x = self.layer3(x)
9     x = self.layer4(x)
10    x = self.avgpool(x)          # Pooling global
11    second_last_outputs = torch.flatten(x, 1) # Embedding
12    x = self.fc(second_last_outputs)         # Clasificador lineal
13    return x, second_last_outputs
```

La tupla (`outputs`, `second_last_outputs`) contiene:

- `outputs`: el logit de dimensión K (número de clases) tras la capa fully-connected $\mathbf{W} \in \mathbb{R}^{K \times p}$.
- `second_last_outputs`: el vector de representación $h \in \mathbb{R}^p$ (con $p = 512$ en ResNet-18 canónico) antes de la capa de clasificación. Es el embedding de la última capa oculta.

Durante el entrenamiento, estas representaciones se acumulan por época:

```
1 outputs, second_last_outputs = model(image)
2 train_repr_list.append(second_last_outputs)
3 y_predict_train_list.append(labels)
4 # ...
5 train_cdnvs_list, mean_list, var_class_cluster_list = \
6     compute_cluster(torch.cat(train_repr_list),
7                     torch.cat(y_predict_train_list))
```

2.2. ResNet-18 (experimentos rf_resnet18)

El archivo `rf_resnet18/training_utils.py` replica exactamente el mismo patrón de extracción, con la diferencia de que ofrece más variantes de regularización (`loss_type1`, `loss_type2`, ortho regularization, phi normalization, spectral/frobenius capping). Sin embargo, el núcleo de la extracción de representaciones es idéntico:

- En ResNet-18 y WideResNet: `outputs, second_last_outputs = model(image)`.
- En EfficientNet-B0/V2: se utiliza `F.adaptive_avg_pool2d(model.forward_features(image), (1, 1)).flatten(1)` como embedding, y `model.classifier.weight` para la norma del clasificador.

2.3. Transformer de Grokking (grokking_nc_rf)

En los experimentos de grokking con el transformer algorítmico, la extracción es sutilmente diferente. El transformer (archivo `grokking_nc_rf/grok/transformer.py`) devuelve cuatro valores:

```
1 def forward(self, x, pos=None, save_activations=False):
2     x = self.embed(x)
3     decoded, attentions, values = self.decoder(x, ...)
4     y_hat = self.linear(decoded) # Proyeccion lineal a vocabulario
5     return y_hat, attentions, values, decoded
```

Aquí, `decoded` es la salida del decodificador *antes* de la proyección lineal final (equivalente a `second_last_outputs`), con forma `[batch_size, context_len, d_model]`. En el método `_step()` de `training.py`, este tensor se transpone y se extraen solo las posiciones relevantes (lado derecho de la ecuación):

```
1 y_hat, attentions, values, decoded_outputs = self(x, ...)
2 decoded_outputs = decoded_outputs.transpose(-2, -1)
3 # Extraer solo las posiciones RHS (despues del '=')
4 decoded_outputs = decoded_outputs[..., eq_position + 1:]
```

Y luego se concatenan para formar la representación conjunta:

```
1 concated_outputs = torch.cat(
2     (decoded_outputs[:, :, 0], decoded_outputs[:, :, 1]), dim=1)
3 hessian_second = torch.sum(
4     torch.mul(concated_outputs, concated_outputs), dim=1)
```

Esta concatenación de los dos tokens de salida (RHS) produce una representación de dimensión $2 \times d_{model}$ que se utiliza tanto para el cálculo de sharpness como para el cómputo de NCC.

2.3.1. Resumen comparativo

Arquitectura	Variable embedding	Dimensión	Uso en NCC
ResNet-18 (nc_exp)	<code>second_last_outputs</code>	512	<code>compute_cluster</code> directo
ResNet-18 (rf_resnet)	<code>second_last_outputs</code>	512	<code>compute_cluster</code> directo
Transformer (grokking)	<code>decoded_outputs</code> concat	$2 \times d_{model}$	Tras concatenación temporal

Cuadro 2.1: Extracción de embeddings en las distintas arquitecturas del repositorio.

Capítulo 3

La Métrica NCC

3.1. Definición formal

La métrica **NCC** (Neural Collapse Clustering) cuantifica el grado de colapso neural en el espacio de representaciones. Se define como:

$$\text{NCC} = \frac{1}{K(K-1)} \sum_{c_1=1}^K \sum_{\substack{c_2=1 \\ c_2 \neq c_1}}^K \frac{\sigma_{c_1}^2 + \sigma_{c_2}^2}{2 \|\mu_{c_1} - \mu_{c_2}\|^2}, \quad (3.1)$$

donde K es el número de clases, $\mu_c \in \mathbb{R}^p$ es la media de las representaciones de la clase c , y σ_c^2 es la varianza intra-clase escalar:

$$\mu_c = \frac{1}{n_c} \sum_{i=1}^{n_c} h_i^{(c)}, \quad \sigma_c^2 = \frac{1}{n_c} \sum_{i=1}^{n_c} \|h_i^{(c)} - \mu_c\|^2. \quad (3.2)$$

3.2. Interpretación geométrica

La métrica NCC se puede interpretar como un cociente entre la varianza intra-clase promedio y la distancia entre medias al cuadrado:

- **NCC = 0**: Colapso perfecto. Toda la varianza intra-clase es cero ($\sigma_c^2 = 0$ para toda c), lo que implica NC1.
- **NCC $\ll 1$** : Colapso fuerte. Las clases forman clusters densos y bien separados.
- **NCC ≈ 1** : Las varianzas intra-clase son comparables a las distancias entre clases. Los clusters se solapan significativamente.
- **NCC > 1** : La dispersión intra-clase es mayor que la separación entre clases. Las representaciones están entremezcladas.

Nótese que NCC captura exclusivamente las propiedades NC1 (varianza intra-clase) y una forma relajada de NC2 (distancia entre medias). No mide directamente la estructura angular (ETF) ni la autodualidad (NC3). Es una métrica agregada que promedia sobre todos los pares de clases.

3.3. Implementación en el código

La implementación se encuentra en `compute_cluster()` en `nc_experiments/training_utils.py`:

```
1 def compute_cluster(train_repr, y_predict_train):
2     # 1. Agrupar representaciones por clase
3     class_dict = {key: [] for key in torch.unique(y_predict_train)}
4     for sub_repr, sub_y in zip(train_repr, y_predict_train):
5         class_dict[sub_y.tolist()].append(sub_repr)
6
7     # 2. Calcular media y varianza intra-clase
8     mean_var_batch_dict = {}
9     for key, value in class_dict.items():
10         temp_mean = torch.mean(torch.stack(value), dim=0)
11         temp_var = torch.mean(torch.stack([
12             torch.linalg.norm(f - temp_mean) ** 2 for f in value]))
13         mean_var_batch_dict[key] = [temp_mean, temp_var]
14
15     # 3. Calcular NCC sobre todos los pares de clases
16     all_train_cdnvs = []
17     for c1 in class_dict.keys():
18         for c2 in class_dict.keys():
19             if c2 == c1: continue
20             mu1, var1 = mean_var_batch_dict[c1]
21             mu2, var2 = mean_var_batch_dict[c2]
22             temp_result = (var1 + var2) / \
23                 (2 * torch.linalg.norm(mu1 - mu2) ** 2)
24             all_train_cdnvs.append(temp_result)
25
26     return torch.mean(torch.stack(all_train_cdnvs))
```

3.3.1. Detalles técnicos importantes

1. **Varianza escalar, no matricial.** En lugar de calcular la matriz de covarianza $\Sigma_W^{(c)} \in \mathbb{R}^{p \times p}$, se usa la traza de dicha matriz: $\sigma_c^2 = \text{tr}(\Sigma_W^{(c)}) = \frac{1}{n_c} \sum_i \|h_i^{(c)} - \mu_c\|^2$. Esto es computacionalmente eficiente pero ignora las correlaciones entre dimensiones.
2. **Distancia euclidiana al cuadrado.** El denominador usa $\|\mu_{c_1} - \mu_{c_2}\|^2$, que es la distancia euclidiana al cuadrado entre medias. Esto conecta directamente con la separabilidad lineal.
3. **Promedio sobre pares.** El valor final es el promedio sobre todos los $K(K - 1)$ pares ordenados de clases distintas. Esto da igual peso a todos los pares, independientemente del tamaño de las clases.

3.4. Relación con otras métricas de colapso

Existen otras métricas en la literatura que cuantifican aspectos complementarios:

- **WHI (Within-class Hessian Invariant):** $\text{tr}(\Sigma_W^{(c)} \Sigma_B^{-1})$, donde Σ_B es la matriz de covarianza entre clases. Esta métrica es más sensible a la estructura de baja dimensionalidad.

- **Norma del ETF:** $\left\| \tilde{M}^\top \tilde{M} - \frac{1}{K-1}(\mathbb{1}_K - \frac{1}{K}\mathbf{1}\mathbf{1}^\top) \right\|_F$, que mide cuán cerca están las medias de clase normalizadas de formar un ETF perfecto.
- **Ángulo promedio entre clasificador y media:** $\frac{1}{K} \sum_c \cos(\hat{W}_c, \hat{\mu}_c)$, que mide NC3.

La métrica NCC es menos sensible a la estructura geométrica fina (angulaciones) pero captura eficazmente la compactación intra-clase y la separación entre clases, que son los aspectos más directamente relacionados con la facilidad de clasificación.

Capítulo 4

Efecto de la Penalización NCC sobre las Representaciones

4.1. Formulación de la función de pérdida

La función de pérdida utilizada en los experimentos con penalización NCC es:

$$\mathcal{L} = \underbrace{\text{CE}(y, \hat{y})}_{\text{cross-entropy}} - \lambda \cdot \underbrace{\text{NCC}(h)}_{\text{cluster metric}}, \quad (4.1)$$

donde $\text{CE}(y, \hat{y})$ es la entropía cruzada estándar, $\lambda > 0$ es un hiperparámetro que controla la fuerza de la penalización, y el signo negativo delante de λNCC significa que estamos *maximizando* (penalizando negativamente) el valor de NCC. Esto es, literalmente:

$$\mathcal{L} = \text{CE}(y, \hat{y}) - \lambda \cdot \left(\frac{\sigma_{c_1}^2 + \sigma_{c_2}^2}{2 \|\mu_{c_1} - \mu_{c_2}\|^2} \right)_{c_1 \neq c_2}. \quad (4.2)$$

Observación 4.1. *El signo negativo es crítico. Mientras que el entrenamiento estándar minimiza implícitamente NCC (porque la CE promueve que las representaciones se colapsen a puntos bien separados [1]), aquí se fuerza explícitamente la dirección opuesta: el gradiente empuja a incrementar NCC.*

4.2. Análisis del gradiente inducido

Para entender el efecto de la penalización, analicemos el gradiente de NCC con respecto a las representaciones. Sea $h_i^{(c)}$ la representación del i -ésimo ejemplo de la clase c . La contribución de este punto a NCC viene dada por:

$$\text{NCC} = \frac{1}{K(K-1)} \sum_{c_1} \sum_{c_2 \neq c_1} \frac{\frac{1}{n_{c_1}} \sum_i \|h_i^{(c_1)} - \mu_{c_1}\|^2 + \frac{1}{n_{c_2}} \sum_j \|h_j^{(c_2)} - \mu_{c_2}\|^2}{2 \|\mu_{c_1} - \mu_{c_2}\|^2}. \quad (4.3)$$

Derivando respecto a una representación específica $h_k^{(c)}$ obtenemos:

$$\frac{\partial \text{NCC}}{\partial h_k^{(c)}} = \frac{1}{K(K-1)} \sum_{c' \neq c} \left[\underbrace{\frac{2(h_k^{(c)} - \mu_c)}{n_c \cdot 2 \|\mu_c - \mu_{c'}\|^2}}_{\text{efecto en varianza}} - \underbrace{\frac{2(\mu_c - \mu_{c'}) (\sigma_c^2 + \sigma_{c'}^2)}{n_c \cdot (2 \|\mu_c - \mu_{c'}\|^2)^2}}_{\text{efecto en distancia}} \right]. \quad (4.4)$$

4.2.1. Interpretación de las componentes del gradiente

La ecuación (4.4) revela dos efectos contrapuestos:

1. **Término de varianza** (primera suma): Empuja a $h_k^{(c)}$ a *alejarse* de la media de su clase μ_c . Esto incrementa la varianza intra-clase y, por tanto, NCC.
2. **Término de distancia** (segunda suma): Empuja a $h_k^{(c)}$ en la dirección que *reduce* la distancia entre μ_c y $\mu_{c'}$, lo que también incrementa NCC. Sin embargo, este término escala con $(\sigma_c^2 + \sigma_{c'}^2)$: cuando las varianzas son pequeñas, domina el primer término.
3. **Efecto neto**: La penalización $-\lambda \text{NCC}$ en la pérdida total implica que el gradiente total incluye $-\lambda \cdot \partial \text{NCC} / \partial h_k^{(c)}$, por lo que durante el descenso de gradiente, las representaciones son empujadas *en dirección contraria* a la indicada por la ecuación (4.4).

4.3. Consecuencias observables

Dado que $\lambda > 0$ y el término es $-\lambda \text{NCC}$, las fuerzas que actúan sobre las representaciones son:

- **La entropía cruzada** empuja a las representaciones a formar clusters compactos y bien separados (NC1 y NC2) porque esto minimiza la pérdida de clasificación.
- **La penalización NCC** invierte esta dinámica: empuja a *aumentar* la varianza intra-clase y a *reducir* la distancia entre medias. Esto deshace activamente el colapso neural.

En equilibrio, las representaciones alcanzan un estado donde ninguna de las dos fuerzas domina completamente. Las propiedades esperables son:

1. **Aumento de σ_c^2** : La varianza intra-clase es significativamente mayor que en el entrenamiento estándar. Las representaciones de una misma clase no se colapsan a un punto, sino que se distribuyen en una región.
2. **Reducción de $\|\mu_{c_1} - \mu_{c_2}\|$** : Las medias de clase están más cercanas entre sí que en el colapso tradicional.
3. **Mantenimiento de la precisión**: A pesar de esto, la precisión en test se mantiene alta porque la CE sigue siendo minimizada. El clasificador lineal aprende a separar regiones (no puntos) en el espacio de representación.
4. **No se observan NC1–NC4 completas**: Las propiedades de Neural Collapse clásico no se satisfacen.

4.4. Ejemplo sintético

Consideremos un caso simplificado con $K = 2$ clases, $p = 2$ dimensiones, $n_1 = n_2 = n$, y representaciones distribuidas isotrópicamente alrededor de cada media:

$$h_i^{(1)} \sim \mathcal{N}(\mu_1, \sigma^2 I), \quad (4.5)$$

$$h_j^{(2)} \sim \mathcal{N}(\mu_2, \sigma^2 I). \quad (4.6)$$

En este caso, el valor esperado de NCC es:

$$\mathbb{E}[\text{NCC}] = \frac{\sigma^2}{\|\mu_1 - \mu_2\|^2}. \quad (4.7)$$

La penalización $-\lambda \text{NCC}$ fuerza a que σ^2 *aumente* o $\|\mu_1 - \mu_2\|^2$ *disminuya* (o ambos). La CE, por su parte, requiere que los clusters sean separables. El conflicto se resuelve cuando las representaciones adoptan una estructura donde la superposición es controlada pero no nula, y el clasificador se adapta a esta nueva geometría.

Capítulo 5

Hipótesis: Colapso Alternativo

Este capítulo constituye la contribución analítica central de este documento. Argumentamos que, si bien la penalización NCC rompe el colapso neural clásico, las representaciones no son caóticas ni carecen de estructura. Proponemos que emerge una *forma alternativa de colapso* con propiedades geométricas distintas.

5.1. Marco conceptual

Definimos un **colapso alternativo** como cualquier configuración de las representaciones $h_i^{(c)} \in \mathcal{H} \subseteq \mathbb{R}^p$ que:

1. Permite alta precisión en clasificación (a través de un clasificador lineal $\mathbf{W}$).
2. No satisface una o más de las propiedades NC1–NC4.
3. Exhibe alguna forma de estructura geométrica o topológica en el espacio de representación.

Bajo la penalización $-\lambda\text{NCC}$, la pérdida total se puede reescribir como un problema de optimización bi-objetivo:

$$\min_{\theta} \text{CE}(y, \hat{y}) + \lambda \cdot \underbrace{[-\text{NCC}(h)]}_{\text{anti-colapso}}, \quad (5.1)$$

que es equivalente a:

$$\min_{\theta} -\frac{1}{N} \sum_{i=1}^N \log \frac{e^{W_{y_i}^\top h_i}}{\sum_c e^{W_c^\top h_i}} + \lambda \cdot \mathbb{E}_{c_1 \neq c_2} \left[-\frac{\sigma_{c_1}^2 + \sigma_{c_2}^2}{2 \|\mu_{c_1} - \mu_{c_2}\|^2} \right]. \quad (5.2)$$

Esta formulación revela que el aprendizaje busca simultáneamente: (a) maximizar la verosimilitud de las etiquetas, lo que favorece representaciones separables, y (b) minimizar el término anti-colapso, que desalienta la compactación intra-clase y la separación entre medias.

5.2. Hipótesis de Colapso por Subespacios (Subspace Collapse)

Hipótesis 5.1 (Subspace Collapse). *Bajo penalización NCC, las representaciones de cada clase no colapsan a un punto, sino a un subespacio afín de baja dimensión contenido en $\mathbb{R}^p$. Específicamente, existe una variedad lineal $\mathcal{M}_c \subset \mathbb{R}^p$ con $\dim(\mathcal{M}_c) \ll p$ tal que:*

$$\frac{1}{n_c} \sum_{i=1}^{n_c} (h_i^{(c)}, \mathcal{M}_c)^2 \ll \frac{1}{n_c} \sum_{i=1}^{n_c} \|h_i^{(c)} - \mu_c\|^2, \quad (5.3)$$

donde $(x, \mathcal{M}) = \min_{m \in \mathcal{M}} \|x - m\|$.

5.2.1. Justificación

La penalización NCC aumenta la varianza escalar σ_c^2 , pero esto no implica necesariamente que la varianza sea isotrópica en todas las direcciones. Es posible que la varianza se concentre en unas pocas direcciones del espacio, mientras que en las direcciones ortogonales las representaciones permanezcan colapsadas. Formalmente, existe una descomposición:

$$\Sigma_W^{(c)} = U_c \Lambda_c U_c^\top, \quad (5.4)$$

donde $\Lambda_c = \text{diag}(\lambda_1^{(c)}, \dots, \lambda_p^{(c)})$ y solo un subconjunto reducido de autovalores $\lambda_j^{(c)}$ son significativos. La traza $\text{tr}(\Sigma_W^{(c)}) = \sum_j \lambda_j^{(c)}$ puede ser grande, pero el rango efectivo $\text{rank}_\epsilon(\Sigma_W^{(c)}) = \#\{j : \lambda_j^{(c)} > \epsilon\}$ puede ser pequeño.

5.2.2. Consecuencias

- El clasificador lineal $\mathbf{W}$ puede aprender pesos que ignoran las direcciones de alta varianza, proyectando las representaciones a un subespacio donde la separación es limpia.
- Esto es consistente con el hecho de que la regularización de peso (weight decay) y el capping espectral (usados en rf_resnet18) limitan la norma de $\mathbf{W}$, forzando al clasificador a usar solo las direcciones más informativas.
- La estructura subespacial permitiría que NCC sea alto (por la varianza en las direcciones ignoradas) mientras la precisión de clasificación se mantiene alta.

5.3. Hipótesis de Colapso Suave (Soft Collapse)

Hipótesis 5.2 (Soft Collapse). *Las representaciones de cada clase no colapsan a puntos ni a subespacios rígidos, sino a regiones conectadas del espacio de representación. Las clases ocupan vecindades (manifolds) que son separables por un clasificador lineal aunque sus centros estén cercanos.*

5.3.1. Formalización

Sea $\mathcal{B}_c(\epsilon) = \{h \in \mathbb{R}^p : (h, \mathcal{S}_c) < \epsilon\}$ la ϵ -vecindad de un conjunto $\mathcal{S}_c$ (la «región» de la clase c). Decimos que hay colapso suave si:

1. $\mathbb{P}(h_i^{(c)} \in \mathcal{B}_c(\epsilon)) \approx 1$ para algún ϵ finito (no necesariamente pequeño).
2. $\mathcal{B}_c(\epsilon) \cap \mathcal{B}_{c'}(\epsilon) = \emptyset$ para $c \neq c'$ (separabilidad).
3. $\frac{1}{n_c} \sum_i \|h_i^{(c)} - \mu_c\|^2 > 0$ incluso en el límite $n_c \rightarrow \infty$ (no colapso a punto).

Observación 5.1. *Esta hipótesis es una relajación de NC1: la varianza intra-clase no tiende a cero, pero las clases permanecen separables. Es análoga a tener conjuntos convexos disjuntos en el espacio de representación.*

5.4. Hipótesis de Colapso Inducido por Kernel (Kernel-Induced Collapse)

Hipótesis 5.3 (Kernel-Induced Collapse). *La separabilidad entre clases en el espacio de representación $h \in \mathbb{R}^p$ no se debe a la geometría euclidiana de h , sino al kernel inducido por el clasificador lineal. Específicamente, el producto escalar $\langle W_c, h \rangle$ induce una métrica diferente en el espacio de representación que hace que las clases sean separables a pesar de que en la métrica euclidiana estándar estén mezcladas.*

5.4.1. Desarrollo

Consideremos la matriz de pesos del clasificador $W \in \mathbb{R}^{K \times p}$. La decisión de clasificación se toma como:

$$\hat{y} = \arg \max_c \langle W_c, h \rangle + b_c. \quad (5.5)$$

Esto es equivalente a medir distancias en una geometría transformada. Definamos la transformación lineal $\phi_W : \mathbb{R}^p \rightarrow \mathbb{R}^K$ como $\phi_W(h) = Wh$. En el espacio de logits, la distancia entre la representación de un punto h y la media de la clase c es:

$$\|\phi_W(h) - \phi_W(\mu_c)\|_W^2 = (h - \mu_c)^\top W^\top W (h - \mu_c). \quad (5.6)$$

Bajo penalización NCC, W puede aprender a «redefinir» la métrica del espacio de representación de manera que, aunque $\|\mu_{c_1} - \mu_{c_2}\|^2$ sea pequeño en la métrica euclidiana, la distancia en la métrica de Mahalanobis inducida por W sea grande:

$$\|\mu_{c_1} - \mu_{c_2}\|_W^2 = (\mu_{c_1} - \mu_{c_2})^\top W^\top W (\mu_{c_1} - \mu_{c_2}) \gg \|\mu_{c_1} - \mu_{c_2}\|^2. \quad (5.7)$$

Proposición 5.1. *El clasificador lineal W puede desacoplar la métrica de clasificación de la métrica euclidiana de las representaciones. La penalización NCC fuerza a que la separabilidad se «transfiera» de h a W .*

5.5. Hipótesis de Colapso con Rango Constreñido (Rank-Constrained Collapse)

Hipótesis 5.4 (Rank-Constrained Collapse). *El rango efectivo del conjunto de medias de clase $\{\mu_c\}_{c=1}^K$ está constreñido por la penalización NCC. En lugar de formar un ETF de rango $K - 1$ (como en NC2), las medias ocupan un simplex de dimensión inferior $r < K - 1$.*

5.5.1. Análisis

En NC2, la matriz de medias centradas $\tilde{M} = [\tilde{\mu}_1, \dots, \tilde{\mu}_K] \in \mathbb{R}^{p \times K}$ tiene rango $K - 1$ y satisface:

$$\tilde{M}^\top \tilde{M} \propto I_K - \frac{1}{K} \mathbf{1}\mathbf{1}^\top. \quad (5.8)$$

Bajo penalización NCC, el término $-\lambda \sigma_c^2 / \|\mu_{c_1} - \mu_{c_2}\|^2$ fuerza que $\|\mu_{c_1} - \mu_{c_2}\|^2$ se reduzca. Esto puede lograrse si las medias de clase se confinan a un subespacio de dimensión reducida:

$$\mu_c = V r_c + \mu_0, \quad \text{con } V \in \mathbb{R}^{p \times r}, \quad r_c \in \mathbb{R}^r, \quad (5.9)$$

donde V es una matriz semi-ortogonal ($V^\top V = I_r$) y μ_0 es un desplazamiento común. Las diferencias entre medias quedan restringidas al subespacio de columnas de V :

$$\|\mu_{c_1} - \mu_{c_2}\|^2 = \|r_{c_1} - r_{c_2}\|^2, \quad (5.10)$$

y si $r < K - 1$, las medias no pueden formar un ETF completo.

Observación 5.2. *Este escenario es compatible con las observaciones de que, en ausencia de colapso neural, las representaciones tienden a ocupar subespacios de menor dimensionalidad efectiva [1, 3]. La penalización NCC podría exacerbar esta tendencia.*

5.6. Unificación: La pérdida como un tradeoff geométrico

Todas las hipótesis anteriores pueden entenderse como diferentes manifestaciones de un mismo principio: la función de pérdida (5.2) define un frente de Pareto entre dos objetivos geométricos en competencia.

Definición 5.1 (Frente de Pareto). *Decimos que una configuración de representaciones $\{h_i^{(c)}\}$ es Pareto-óptima si no existe otra configuración que simultáneamente reduzca CE y reduzca $-NCC$ (i.e., aumente NCC). El conjunto de todas las configuraciones Pareto-óptimas forma el frente de Pareto.*

En el límite $\lambda \rightarrow 0$, recuperamos el colapso neural clásico (NC). En el límite $\lambda \rightarrow \infty$, las representaciones maximizarían NCC, potencialmente volviéndose caóticas (pero la CE dejaría de minimizarse). Para λ finito y positivo, las representaciones se sitúan en algún punto intermedio del frente de Pareto.

La Figura 5.1 ilustra esquemáticamente este tradeoff.




Figura 5.1: Representación esquemática del frente de Pareto entre CE y $-NCC$. El colapso neuronal clásico (punto rojo superior izquierdo) minimiza NCC a expensas de un CE bajo. El colapso alternativo (punto rojo inferior derecho) permite mayor NCC (menos colapso) mientras mantiene el CE competitivo.

5.7. Evidencia empírica preliminar

El repositorio `grokking_flatness` contiene evidencia que respalda la existencia de colapso alternativo:

1. En los experimentos `nc_experiments`, el modelo entrenado con $\lambda > 0$ generaliza bien a pesar de que NCC es significativamente mayor que en el caso sin regularización (ver paper original [2]).
2. Las gráficas del paper muestran que, mientras la sharpness relativa (RF) correlaciona con la generalización, el NCC no muestra una correlación clara con la aparición del grokking.
3. En los transformers algorítmicos, los embeddings `decoded_outputs` preservan estructura suficiente para que la proyección lineal aprenda a decodificar correctamente, incluso cuando NCC es alto.
4. El capping espectral y de Frobenius en `rf_resnet18` limita la norma de W , lo que obliga al modelo a depender de la geometría de h en lugar de adaptar W arbitrariamente.

Capítulo 6

Propuestas de Análisis

Para validar las hipótesis planteadas en el Capítulo 5, proponemos un conjunto de análisis cuantitativos que podrían implementarse sobre los datos de representaciones ya generados en el repositorio.

6.1. Análisis de NCC por capas

Hipótesis 6.1 (Colapso Temprano). *Aunque NCC sea alto en la última capa (por efecto de la penalización), las capas intermedias podrían exhibir colapso neural clásico. La penalización solo afecta a la última representación, pero las capas anteriores podrían mantener estructura colapsada.*

Propuesta: Extraer representaciones de todas las capas de la red (no solo la última) y calcular NCC en cada una. Idealmente, observaríamos una transición: NCC bajo en capas tempranas $\rightarrow$ NCC alto en la última capa penalizada.

$$\text{NCC}^{(\ell)} = \frac{1}{K(K-1)} \sum_{c_1 \neq c_2} \frac{\sigma_{c_1}^{2(\ell)} + \sigma_{c_2}^{2(\ell)}}{2 \left\| \mu_{c_1}^{(\ell)} - \mu_{c_2}^{(\ell)} \right\|^2}, \quad (6.1)$$

donde el superíndice (ℓ) indica la capa ℓ -ésima.

6.2. Análisis de Componentes Principales (PCA) de las medias de clase

Hipótesis 6.2 (Dimensionalidad Reducida). *Bajo penalización NCC, las medias de clase μ_c ocupan un subespacio de dimensionalidad menor que $K-1$.*

Propuesta: Realizar PCA sobre la matriz de medias centradas $\tilde{M} \in \mathbb{R}^{p \times K}$ y analizar el espectro de autovalores:

$$S = \tilde{M}^\top \tilde{M}, \quad \text{autovalores } \eta_1 \geq \eta_2 \geq \dots \geq \eta_K. \quad (6.2)$$

En NC2 puro, $\eta_1 = \eta_2 = \dots = \eta_{K-1} > 0$ y $\eta_K = 0$, con la relación $\eta_i/\eta_1 = 1$ para $i \leq K-1$. Bajo colapso alternativo:

- La caída espectral podría ser más rápida: $\eta_2 \ll \eta_1$.

- El rango efectivo $r = \#\{i : \eta_i > \epsilon\eta_1\}$ podría ser menor que $K - 1$.
- La uniformidad η_{K-1}/η_1 se desvía del valor ideal 1.

Métricas concretas:

$$\text{Rango efectivo} = \frac{(\sum_{i=1}^K \eta_i)^2}{\sum_{i=1}^K \eta_i^2} \quad (\text{participación}) \quad (6.3)$$

$$\text{Uniformidad} = \frac{\eta_{K-1}}{\eta_1} \quad (\text{ideal: } 1) \quad (6.4)$$

6.3. Información Mutua entre Representación y Etiqueta

Hipótesis 6.3 (Compresión de Información). *La penalización NCC podría inducir una compresión de la información en las representaciones: la información mutua $MI(h; y)$ entre la representación h y la etiqueta y se mantiene alta (necesaria para clasificación), pero la información $MI(h; x)$ entre h y la entrada x se reduce (las representaciones retienen menos información posicional o de detalle).*

Propuesta: Estimar la información mutua usando estimadores kNN [4] o mediante histogramas adaptativos:

$$MI(h; y) = \mathbb{E}_{p(h,y)} \left[\log \frac{p(h, y)}{p(h)p(y)} \right], \quad (6.5)$$

$$MI(h; x) = \mathbb{E}_{p(h,x)} \left[\log \frac{p(h, x)}{p(h)p(x)} \right]. \quad (6.6)$$

La hipótesis predice:

$$MI_{\text{penalizado}}(h; y) \approx MI_{\text{estándar}}(h; y), \quad MI_{\text{penalizado}}(h; x) < MI_{\text{estándar}}(h; x). \quad (6.7)$$

6.4. Distancias geodésicas en el manifold de representaciones

Hipótesis 6.4 (Geometría No Euclidiana). *La estructura de las representaciones bajo penalización NCC es mejor capturada por distancias geodésicas (intrínsecas al manifold) que por distancias euclidianas. Las clases son separables geodésicamente aunque no lo sean euclidianamente.*

Propuesta: Construir un grafo de vecinos más cercanos (k -NN) sobre el conjunto de representaciones $\{h_i\}_{i=1}^N$ y calcular la distancia geodésica $d_G(c_1, c_2)$ como el camino más corto en el grafo entre cualquier punto de la clase c_1 y cualquier punto de la clase c_2 :

$$d_G(c_1, c_2) = \min_{i: y_i = c_1} \min_{j: y_j = c_2} \text{dist}_{\text{grafo}}(h_i, h_j). \quad (6.8)$$

Comparar d_G con la distancia euclidiana $\|\mu_{c_1} - \mu_{c_2}\|$. La hipótesis predice que la relación $d_G / \|\mu_{c_1} - \mu_{c_2}\|$ es mayor bajo penalización NCC (las clases están más «enrolladas» en el manifold).

6.5. Análisis de la matriz Gram de medias

Hipótesis 6.5 (Estructura de ETF Deformada). *La matriz Gram de las medias de clase normalizadas $G_{c_1 c_2} = \langle \hat{\mu}_{c_1}, \hat{\mu}_{c_2} \rangle$, donde $\hat{\mu}_c = \mu_c / \|\mu_c\|$, se desvía de la estructura de ETF ideal $G^{ETF} = \frac{1}{K-1}(\mathbf{1}\mathbf{1}^\top - I) + I$ de manera sistemática.*

Propuesta: Calcular las métricas de desviación:

$$\Delta_{\text{ETF}} = \|G - G^{\text{ETF}}\|_F, \quad (6.9)$$

$$\Delta_{\text{angular}} = \max_{c_1 \neq c_2} \left| \langle \hat{\mu}_{c_1}, \hat{\mu}_{c_2} \rangle - \left(-\frac{1}{K-1} \right) \right|. \quad (6.10)$$

Si las medias colapsan a un subespacio de menor dimensión, los ángulos entre ellas se alejarán del valor ideal $-\frac{1}{K-1}$, tendiendo hacia ángulos más cercanos a 0 (menos ortogonalidad).

6.6. NCC local vs. global

Hipótesis 6.6 (Colapso Local). *Aunque el NCC global (promediado sobre todas las clases) sea alto, el NCC local (calculado solo sobre vecinos cercanos) podría ser bajo. Esto indicaría que las clases son localmente colapsadas pero globalmente dispersas.*

Propuesta: Definir NCC local como:

$$\text{NCC}_{\text{local}} = \frac{1}{N} \sum_{i=1}^N \sum_{j \in \mathcal{N}_k(i)} \frac{\|h_i - \mu_{y_i}\|^2 + \|h_j - \mu_{y_j}\|^2}{2 \|\mu_{y_i} - \mu_{y_j}\|^2} \cdot \mathbb{1}_{y_i \neq y_j}, \quad (6.11)$$

donde $\mathcal{N}_k(i)$ son los k vecinos más cercanos de h_i . Si $\text{NCC}_{\text{local}} \ll \text{NCC}_{\text{global}}$, esto sugiere que la estructura local de vecindad está mejor organizada que la estructura global.

6.7. Análisis de la topología del espacio de representación

Hipótesis 6.7 (Persistencia Homológica). *La topología del espacio de representación (medida mediante homología persistente) cambia bajo penalización NCC. En particular, los componentes conectados y los agujeros en el espacio de representación se reorganizan.*

Propuesta: Utilizar *persistent homology* (herramientas como **Ripser** o **GUDHI**) para calcular los números de Betti $\beta_0, \beta_1, \beta_2$ del complejo de Čech o Vietoris-Rips construido sobre las representaciones. Comparar la persistencia de las características topológicas entre:

- Modelo estándar ($\lambda = 0$): se esperan K componentes conectados claros ($\beta_0 = K$) que persisten para rangos de escala amplios.
- Modelo penalizado ($\lambda > 0$): los K componentes podrían estar conectados por puentes de alta densidad ($\beta_0 < K$ para escalas pequeñas), indicando que las regiones de clase están topológicamente más cerca.

6.8. Visualización mediante UMAP / t-SNE

Aunque cualitativo, la visualización de las representaciones mediante técnicas de reducción de dimensionalidad no lineal (UMAP [5], t-SNE [6]) puede revelar patrones que las métricas agregadas no capturan.

Propuesta: Proyectar las representaciones a 2D con UMAP y colorear por clase. Comparar las visualizaciones para:

- $\lambda = 0$: Clusters densos y separados (NC1 visual).
- $\lambda > 0$: Clusters más difusos pero aún separables, posiblemente con estructura elongada o en forma de «cinta».

Métrica	$\lambda = 0$ (NC)	$\lambda > 0$ (Alt)
NCC	≈ 0	> 0
σ_c^2	$\rightarrow 0$	> 0
$\ \mu_{c_1} - \mu_{c_2}\ $	grande	reducido
Rango efectivo de medias	$K - 1$	$r < K - 1$
Δ_{ETF}	≈ 0	> 0
$\text{MI}(h; y)$	alta	alta
$\text{MI}(h; x)$	alta	reducida
β_0 persistente	K	$< K$

Cuadro 6.1: Resumen de las predicciones de las métricas bajo colapso neural estándar vs. colapso alternativo.

Capítulo 7

Conclusiones

7.1. Síntesis de los hallazgos

El análisis presentado en este documento revela que la penalización explícita de Neural Collapse mediante el término $-\lambda\text{NCC}$ en la función de pérdida produce un efecto profundo y sistemático en la geometría de las representaciones latentes. Las conclusiones principales son:

1. **NC no es necesario para generalizar.** Como demuestran Han et al. [2], los modelos entrenados con penalización NCC generalizan bien aunque las propiedades NC1–NC4 no se satisfagan. Esto establece que Neural Collapse es una condición *suficiente pero no necesaria* para la generalización.
2. **La penalización NCC induce un conflicto geométrico.** La pérdida $\text{CE} - \lambda\text{NCC}$ enfrenta dos fuerzas opuestas: la entropía cruzada favorece el colapso (clusters compactos y separados), mientras que la penalización NCC lo deshace. Las representaciones resultantes son un compromiso entre ambos objetivos.
3. **Emergen formas alternativas de colapso.** Proponemos que, lejos de ser caóticas, las representaciones bajo penalización NCC adoptan estructuras alternativas:
 - **Subspace Collapse:** la varianza intra-clase se concentra en unas pocas direcciones.
 - **Soft Collapse:** las clases ocupan regiones separables aunque no colapsen a puntos.
 - **Kernel-Induced Collapse:** el clasificador redefine la métrica de separación.
 - **Rank-Constrained Collapse:** las medias ocupan un simplex de dimensión reducida.
4. **El clasificador lineal se adapta a la nueva geometría.** El aprendizaje de $\mathbf{W}$ se acopla a la geometría de h de manera que la separabilidad se mantiene incluso cuando las representaciones no están colapsadas. Las técnicas de capping espectral y de Frobenius en `rf_resnet18` modulan aún más este acoplamiento.

7.2. Hacia una teoría unificada

Proponemos el término «**Colapso Geométrico**» (*Geometric Collapse*) para referirnos a la familia de configuraciones de representaciones que permiten alta precisión de clasificación sin satisfacer Neural Collapse clásico. Esta noción más amplia incluye tanto el colapso neural tradicional como las formas alternativas descritas aquí.

El colapso geométrico se caracterizaría por:

$$\lim_{n_c \rightarrow \infty} \frac{1}{n_c} \sum_{i=1}^{n_c} \ell(h_i^{(c)}, \mu_c, \{\mu_{c'}\}_{c' \neq c}, \mathbf{W}) = \epsilon \geq 0, \quad (7.1)$$

donde ℓ es una función de pérdida que mide la «calidad de la representación» y ϵ es una cota inferior que puede ser cero (NC) o positiva (colapso alternativo).

7.2.1. Trabajo futuro

Los análisis propuestos en el Capítulo 6 permitirían validar empíricamente las hipótesis aquí planteadas. En particular, recomendamos:

1. Implementar el cálculo de NCC por capas para determinar si el colapso alternativo es un fenómeno de la última capa o afecta a toda la red.
2. Realizar PCA y SVD de las medias de clase para cuantificar la dimensionalidad efectiva del espacio de representaciones bajo distintos valores de λ .
3. Calcular la información mutua $MI(h; y)$ y $MI(h; x)$ para entender el tradeoff de compresión.
4. Explorar métodos de topología persistente (TDA) para caracterizar la estructura global del espacio de representación.
5. Investigar si las conclusiones se extienden a arquitecturas más grandes (ViT, GPT-2) y otros dominios (NLP, visión).

7.3. Reflexión final

La clave conceptual de este trabajo es que la relación entre representaciones y generalización es más sutil que «a más colapso, mejor generalización». El colapso neural es una manifestación de la minimización de la entropía cruzada en el régimen de sobreparametrización, pero no es la *única* configuración geométrica que permite generalizar.

La penalización NCC revela que las redes neuronales tienen una plasticidad geométrica considerable: pueden encontrar configuraciones de representaciones muy diferentes de las clásicas y, sin embargo, igual de efectivas para la clasificación. Esto sugiere que la generalización depende más de propiedades de regularidad (como la suavidad del clasificador o la geometría del espacio de representación a nivel de manifold) que de la compacidad de los clusters.

En palabras de Han et al.: «*Flatness is necessary; Neural Collapse is not*». Nuestro análisis complementa esta conclusión al preguntar: «¿Qué forma geométrica toman las representaciones cuando Neural Collapse no ocurre?» La respuesta, que hemos esbozado aquí, apunta a un rico paisaje de estructuras alternativas que merecen ser exploradas en profundidad.

Apéndice A

Detalles de Implementación en el Código

A.1. Cálculo de Sharpness

En los experimentos de `nc_experiments` y `rf_resnet18`, la sharpness se calcula como:

$$\text{Sharpness} = \|W\|_2 \cdot \sum_j \left[\sum_c p_c(1 - p_c) \right]_j \cdot \|h_j\|^2, \quad (\text{A.1})$$

donde W son los pesos del clasificador, $p_c = \text{softmax}(z)_c$ con $z = Wh + b$, y h_j es la representación del j -ésimo ejemplo en el batch.

El código correspondiente es:

```
1 probs = torch.softmax(outputs, dim=1)
2 hessian_first = torch.sum(torch.mul(probs, 1 - probs), dim=1)
3 hessian_second = torch.sum(torch.mul(second_last_outputs,
   second_last_outputs), dim=1)
4 hessian = torch.mul(hessian_first, hessian_second)
5 weights_norm = torch.linalg.norm(model.fc.weight)
6 sharpness = weights_norm * hessian
7 sharpness2 = weights_norm * weights_norm * hessian
```

A.2. Variantes de regularización en `rf_resnet18`

El archivo `rf_resnet18/training_utils.py` incluye múltiples variantes de la pérdida:

- `loss_type1`: $\mathcal{L} = \text{CE} - \lambda \cdot \overline{\text{sharpness}^2}$ (penalización de sharpness estándar).
- `loss_type2`: $\mathcal{L} = \text{CE} - \lambda \cdot \frac{\overline{\text{sharpness}^2}}{|\text{CE}| + \epsilon}$ (penalización normalizada).
- `loss_ortho`: Añade un término de ortonormalidad: $+\rho \cdot \|WW^\top - I\|_F^2$.
- `use_pow`: Penalización NCC en lugar de sharpness: $\mathcal{L} = \text{CE} - \lambda \cdot \text{NCC}$.

A.3. Extracción de representaciones en ViT y BERT

Para ViT, las representaciones se extraen de manera análoga a ResNet, tomando la salida anterior a la cabeza de clasificación. Para BERT (en `rf_bert/bert_sst5.py`) y GPT-2 (en `rf_gpt2/gpt_sst5.py`), se utiliza el token [CLS] (para BERT) o la última capa oculta promediada (para GPT-2) como representación, antes de la proyección lineal final.

Bibliografía

- [1] V. Pappas, X. Y. Han, and D. L. Donoho. *Prevalence of neural collapse during the terminal phase of deep learning training*. Proceedings of the National Academy of Sciences, 117(40):24652–24663, 2020.
- [2] T. Han, L. Adilova, H. Petzka, J. Kleesiek, and M. Kamp. *Flatness is Necessary, Neural Collapse is Not: Rethinking Generalization via Grokking*. NeurIPS 2025.
- [3] Z. Zhu, T. Ding, J. Zhou, X. Li, C. You, J. Sulam, and Q. Qu. *A geometric analysis of neural collapse with unconstrained features*. NeurIPS 2021.
- [4] L. F. Kozachenko and N. N. Leonenko. *Sample estimate of the entropy of a random vector*. Problems of Information Transmission, 23(2):95–101, 1987.
- [5] L. McInnes, J. Healy, and J. Melville. *UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction*. arXiv:1802.03426, 2018.
- [6] L. van der Maaten and G. Hinton. *Visualizing data using t-SNE*. Journal of Machine Learning Research, 9:2579–2605, 2008.