

Informe del Artículo: Positional versus Symbolic Attention Heads

Autores originales: Felipe Urrutia, Juan José Alegría,
Cinthia Sanchez Macias, Jorge Salas, Cristian B. Calderon,
Cristobal Rojas

Afiliación: CENIA & Faculty of Mathematics UC, Santiago, Chile
arXiv: 2605.31558 (NeurIPS 2026)

Abstract—Este artículo estudia cómo los attention heads en transformers desarrollan comportamientos posicionales versus simbólicos durante el entrenamiento, y cómo estos comportamientos afectan la capacidad de generalización a secuencias más largas. Se introducen tareas estructuralmente equivalentes que requieren perfiles de atención distintos, se define una descomposición mecanicista en funciones básicas (Index, Retrieval, Reflexive), y se presenta un análisis teórico de cómo RoPE puede implementar estas funciones con interpretación geométrica, estableciendo cotas de discrepancia que explican cuantitativamente la degradación con la longitud de secuencia.

I. MOTIVACIÓN Y CONTEXTO

Los transformers modernos (GPT, Claude, etc.) usan **Rotary Positional Encoding (RoPE)** para codificar información posicional. Sin embargo, no se entendía bien cómo los attention heads aprenden a usar la información posicional (atender a posiciones específicas) versus información simbólica (atender a tokens específicos sin importar su posición).

Trabajo previo de Urrutia et al. (2025) introdujo **métricas** para clasificar heads como posicionales o simbólicas, y observaron que en modelos reales las capas tempranas tienden a ser posicionales y las profundas simbólicas. Este artículo **extiende ese análisis al estudio de la dinámica de aprendizaje** y a la **generalización a largo contexto**.

II. TAREAS PROPUESTAS

A. Number Task (Tarea Numérica)

- **Entrada:** Una secuencia de letras seguida de números.
- **Mecanismo:** Cada número indica cuántas posiciones retroceder en la secuencia.
- **Ejemplo (4-hop):** C B A . . . 1 4 1 3 2 1 1 $\rightarrow$ hop1: retrocede 1 $\rightarrow$ hop2: retrocede 4 $\rightarrow$ hop3: retrocede 1 $\rightarrow$ hop4: retrocede 3 $\rightarrow$ respuesta: letra en posición final.
- **Tipo de razonamiento:** Posicional – requiere seguir posiciones relativas.
- **Vocabulario:** 120 letras (a–z + bigramas aa–dp) + 16 enteros $\{1, \dots, 16\}$ = 136 tokens.

B. Letter Task (Tarea de Letras)

- **Entrada:** Una secuencia de pares letra-letra seguida de pares letra-número.

- **Mecanismo:** Cada par (X, Y) indica “busca el par cuya primera letra es Y ”.
- **Ejemplo (4-hop):** $(I, G) (G, D) (D, E) (E, C) (H, F) \dots (C, 2) \rightarrow$ hop1: G busca a $(I, G) \rightarrow$ hop2: D busca a $(G, D) \rightarrow \dots \rightarrow$ respuesta: $(C, 2)$.
- **Tipo de razonamiento:** Simbólico – requiere seguir asociaciones entre símbolos.
- **Vocabulario:** 8 letras $\{a, \dots, h\}$ + 8 enteros $\{1, \dots, 8\}$ = 64 pares $\times$ 2 tipos = 128 tokens.

Ambas tareas son **estructuralmente equivalentes** (misma estructura multi-hop), pero demandan **mecanismos distintos**.

III. CONFIGURACIÓN EXPERIMENTAL

A. Arquitectura del Modelo

- **Modelo:** GPT-J (decoder-only Transformer)
- **Capas:** 12
- **Attention heads:** 1 por capa (single-head, para aislar mecanismos)
- **Dimensión oculta:** 128
- **Posicional encoding:** RoPE
- **Activación:** GELU
- **Dropout:** 0.1
- **Objetivo:** Last-token prediction (solo se optimiza la pérdida en el último token)

B. Dataset

- **480,000 secuencias** por tarea
- Cada secuencia: 17 tokens (8 target window + 8 pre-target window + 1 query)
- Balanceado: misma proporción de casos 1-hop, 2-hop, 3-hop, 4-hop
- Split: 90% train / 0.5% validation / 9.5% test

C. Entrenamiento

- Entrenamiento con 3 NVIDIA RTX A5000 (24GB cada una)
- Tiempo total: $\sim$ 55 minutos por modelo
- Métricas de positional/symbolic score: 10h GPU + 17h CPU

IV. MÉTRICAS: POSITIONAL Y SYMBOLIC SCORES

Basado en Urrutia et al. (2025), se definen dos métricas para cuantificar el comportamiento de un attention head.

A. Definición Formal

Un head actúa **posicionalmente** si su distribución de atención es **invariante** ante permutaciones de los key vectors. Es decir, atiende a posiciones específicas sin importar qué token esté ahí.

Un head actúa **simbólicamente** si su distribución de atención es **equivariante** ante permutaciones. Es decir, atiende a tokens específicos sin importar su posición.

B. Scores

Se calculan mediante:

- **Permutaciones por pares** (swaps) entre posiciones i, j
- **Peso de cada permutación** basado en la masa de atención movida (softmax con temperatura)
- **Positional Score**: Similitud coseno entre atención original y atención tras permutar
- **Symbolic Score**: Similitud coseno entre atención original y atención “canónica” tras permutar

V. RESULTADOS PRINCIPALES

A. Dinámica de Aprendizaje (Figura 2)

Number Task:

- El accuracy emerge **progresivamente**: primero se aprende 1-hop, luego 2-hop, etc.
- Se requieren **heads posicionales** para el Indexing + **heads simbólicas** para propagación.
- Las heads posicionales aparecen en capas medias (L3–L6).
- Las heads simbólicas aparecen en capas profundas (L9–L11).

Letter Task:

- El accuracy emerge **simultáneamente** para todos los hops.
- Solo se requieren **heads simbólicas** (Retrieval).
- La última head simbólica en L11 es necesaria para todos los hops.
- Las heads posicionales no son necesarias.

B. Pureza de Heads

La **pureza** (heads que son claramente posicionales O simbólicas, no mixtas) es necesaria para alcanzar máxima precisión. Esto valida las métricas como herramienta de interpretabilidad.

C. Funciones Mecanicistas Identificadas

Tres funciones básicas implementadas por los heads puros:

- 1) **Selective Index (Index)**: Dada una posición con un número n , copia el token n posiciones atrás, pero solo si es una letra. → **Posicional**
- 2) **Retrieval**: Dado un par (X, Y) , busca el par anterior cuya primera letra sea Y y lo copia. → **Simbólico**
- 3) **Reflexive**: Copia el token actual a la siguiente capa sin cambios. → Puede ser posicional o simbólico (en la práctica, simbólico).

D. Descomposición Mecanicista

Para una entrada con h hops y un modelo con $\ell \geq h$ capas:

- **Number Task**: $f_{\text{Num}}(\sigma) = \text{Reflexive}^{(\ell-h)}(\text{Index}^h(\sigma))[n]$
- **Letter Task**: $f_{\text{Let}}(\sigma) = \text{Reflexive}^{(\ell-h)}(\text{Retrieval}^h(\sigma))[n]$

VI. ANÁLISIS TEÓRICO: MECANISMOS GEOMÉTRICOS EN ROPE

A. Teorema 3.1 (Factibilidad)

Existe un Transformer T_{Index} con atención RoPE 2D que implementa Index, y un $T_{\text{Retrieval}}$ que implementa Retrieval, ambos con una sola cabeza de atención y sin funciones de activación.

Mecanismo para Index (Posicional):

- Key vectors: todos alineados (iguales a un vector v)
- Query vectors: codifican la posición a atender mediante rotación RoPE
- La atención máxima ocurre exactamente en la posición deseada ($n - \sigma_n$)
- Los value vectors solo copian si el token es letra (mapeo diagonal)

Mecanismo para Retrieval (Simbólico):

- Key vectors: codifican la letra izquierda del par mediante rotación con ángulo ω
- Query vectors: codifican la letra derecha del par consultante
- La atención máxima ocurre donde la letra izquierda del key coincide con la letra derecha del query
- La posición exacta no importa, solo la identidad del símbolo

B. Remark 3.1

Index **no puede** implementarse con un head puramente simbólico. Retrieval **no puede** implementarse con un head puramente posicional.

Esto demuestra la **separación fundamental** entre ambos tipos de mecanismos.

VII. ANÁLISIS DE ROBUSTEZ: DISCREPANCIA

A. Definición de Discrepancia (Definición 3.1)

La **discrepancia** Δ de un attention head es la diferencia máxima entre el logit más grande y el segundo más grande para entradas de cierta longitud.

Intuitivamente: mide qué tan distinguible es el token correcto del resto. Una discrepancia de 0 significa que el modelo no puede distinguir el token correcto.

B. Teorema 3.2 (Cotas de Discrepancia)

Para Index (posicional):

$$\Delta_{\text{Index}}(n) \leq \min \left\{ 1 - \cos(\theta), \frac{\pi^2}{2n^2} \right\}$$

Para Retrieval (simbólico):

$$\Delta_{\text{Retrieval}}(n) \leq 1 - \cos(\omega - n\theta)$$

Interpretación:

- Index: la discrepancia decae como $\mathcal{O}(1/n^2)$ – se degrada rápidamente con la longitud.
- Retrieval: la discrepancia se mantiene **no nula** incluso para n grandes si θ es pequeño.
- Si $\theta = 0$ (NoPE), $\Delta_{\text{Retrieval}}$ se mantiene positiva para cualquier longitud.

Esto demuestra cuantitativamente que **los mecanismos simbólicos generalizan mejor** a secuencias largas.

C. Validación Experimental (Figura 5)

Los resultados confirman las predicciones teóricas:

Modelo entrenado GPT-J:

- Letter task: $> 90\%$ de precisión hasta 850 tokens ($53 \times$ la longitud original)
- Number task: la precisión cae rápidamente después de la longitud de entrenamiento

Modelos frontera (GPT 5.4, GPT 5.5, Claude Sonnet 3.7):

- Letter task: precisión > 0.88 a longitud 32, > 0.65 a longitud 100
- Number task: precisión < 0.5 a longitud 32, < 0.1 a longitud 100
- Consistente con las predicciones del Teorema 3.2

VIII. CONCLUSIONES Y CONTRIBUCIONES

A. Contribuciones Principales

- 1) **Tareas estructuralmente equivalentes** que requieren perfiles de atención distintos (posicional vs. simbólico).
- 2) **Relación entre pureza de heads y precisión:** La máxima precisión requiere heads puros (claramente posicionales o simbólicos).
- 3) **Descomposición mecanicista** de ambas tareas en funciones básicas (Index, Retrieval, Reflexive).
- 4) **Construcciones teóricas** que muestran cómo RoPE puede implementar estas funciones con interpretación geométrica.
- 5) **Noción de discrepancia** para cuantificar la degradación con la longitud.
- 6) **Separación cuantitativa** entre mecanismos posicionales y simbólicos en términos de generalización.

B. Implicaciones

- Los mecanismos simbólicos son **intrínsecamente más robustos** para longitudes largas.
- Esto sugiere que entrenar modelos para que desarrollen estrategias simbólicas (vs. posicionales) puede mejorar la generalización.
- Las métricas positional/symbolic scores pueden servir como **herramienta de monitoreo** durante el entrenamiento de LLMs.

C. Limitaciones

- Configuración controlada con single-head por capa (no multi-head como modelos reales).
- Vocabulario finito limita pruebas de extrapolación.
- Solo se estudiaron tareas multi-hop simples.

REFERENCIAS CLAVE

- 1) Urrutia et al. (2025) — “Decoupling positional and symbolic attention behavior in transformers” (arXiv:2511.11579) — Introduce las métricas positional/symbolic scores.
- 2) Barbero et al. (2024) — “Round and round we go! What makes rotary positional encodings useful?” — Observa que heads simbólicas usan frecuencias bajas de RoPE.
- 3) Su et al. (2024) — “RoFormer: Enhanced Transformer with Rotary Position Embedding” — Paper original de RoPE.
- 4) Pasten et al. (2025) — “Continuity and isolation lead to doubts or dilemmas in large language models” — Sobre la dispersión de atención con softmax.